km2.md 4/28/2022

## Plan działania:

- Mapowanie abstraktu na wektory:
  - TF-idf
  - Ekstrakja ficzerów z TF-idf
    - Wyrzucić te, które są wszędzie, albo prawie nigdzie
    - select k-best
    - Recursive feature elimination
- Dorzucenie własnych ficzerów:
  - Afiliacja openalex
    - Usunięcie rzadkich i wrzucenie do jednej kategorii
  - Typ dokumentu openalex
    - czy to jest artykuł, czy coś innego
  - "Ważność afiliacji" własna zmienna
    - \$log(\frac{#{\textrm{ilość wszyskich paperów}}}{#{\textrm{ilość paperów z którymi jest dana instyyucja powiązana}}})\$
    - Powyższa wartość by była w one-hot wektorze zamiast 1
  - Liczba cytowań w innych paperach altmetrics
  - Autor openalex
    - Jeżeli wyjdzie coś sensownego, to coś analogicznego do ważności afiliacji
  - Kategoria MAG openalex
  - Czy to otwarty dostęp openalex